



Architecture du Pipeline Analytique : Du Raw Data au Rapport Automatisé



Étape 1 : De 693k à 62.8k Noyaux "High Confidence"


Gestion Mémoire



Lecture "Backed Mode"

Traitement d'un H5AD de 6.3 Go sans saturer la mémoire, une décision d'ingénierie clé.

Filtrage Multi-niveaux




Critères de QC Stricts




Justification des Seuils

- "pct_counts_mt < 5%" : Élimination du stress cellulaire, un artefact technique connu en snRNA-seq.
- "n_genes > 1000" : Rejet des débris nucléaires.
- "n_genes < 6000" : Rejet des doublets potentiels.

Étape 2 : Révéler l'Hétérogénéité Cellulaire avec Scanpy




Résultat 1 : Clustering non supervisé



23 clusters de Leiden identifiés (résolution 0.5), révélant une granularité fine.

Résultat 2 : Annotation Manuelle Raisonnée




Annotation en 8 macro-types robustes.

Décision clé :

Le cluster **`Microglia DAM/Activated`** (Cl. 18) a été regroupé car 98% de ses cellules provenaient d'un seul donneur, le rendant non-viable pour une analyse DGE.

Étape 3 : La Stratégie "Pseudobulk" pour une Inférence Statistique Valide


Le Problème : La Pseudo-réplication en Single-Cell



Les cellules d'un même donneur ne sont **PAS** des répliquats indépendants. Les traiter comme tels inflaterait massivement les faux positifs.

La Solution : L'Agrégation par Donneur et Type Cellulaire

Création d'un sample_id unique : cell_type_annotation + donor_id.



**Σ (comptages UMI bruts)
par groupe**

Le Résultat : Des Matrices Prêtes pour l'Analyse en R

pseudobulk_counts.csv


	Échantillon 1	Échantillon 2	...	Échantillon 96
Gène A	120	85	...	42
Gène B	95	85	...	42
Gène C	85	85	...	42
Gène D	...	...	...	...
...	...	...	...	...

pseudobulk_metadata.csv

	disease	sex	age	cell_type
Échantillon 1	AD	M	68	Excitatory
Échantillon 2	AD	M	68	Excitatory
...	...	...	...	...
Échantillon 96	AD	M	68	Excitatory


Étape 4 : Extraire le Signal Biologique face à un Manque de Puissance

Le Défi : Puissance Statistique Limitée




Avec N=3 pour le groupe Parkinson, la correction FDR est trop conservative. `adj.P.Val < 0.05` est inatteignable.

Notre Solution : Le Volcano Plot "Intelligent"



- Non significatif ($P > 0.01$)
- Tendance Biologique ($P < 0.01$ mais $FDR > 0.05$)
- Signal Robuste ($FDR < 0.05$)

De la Tendance à l'Hypothèse



Le script Python/Seaborn génère automatiquement des heatmaps des meilleures tendances, permettant de formuler des hypothèses biologiques même en l'absence de significativité statistique stricte.


Étape 5 : Le Rapport "Zéro Copier-Coller" pour une Reproductibilité Totale

Le Problème : Le Rapport Manuel



- Risque d'erreurs, non-reproductible, perte de temps critique.

La Solution : Assemblage Dynamique avec `python-docx`



Un script lit un template, injecte les assets et les métriques de manière programmatique.

Le Bénéfice : Intégrité et Efficacité



Si un seuil de QC change à l'étape 1, le rapport final est mis à jour en exécutant une seule commande. La cohérence est assurée de bout en bout.

Un Pipeline Scalable, Auditable et Reproductible

La Stack Technique



Écosystème Python 3.9+

- `Scanpy` & `AnnData` : Cœur de l'analyse single-cell.
- `Pandas` : Manipulation et agrégation des données.
- `Seaborn` & `Matplotlib` : Visualisation avancée.
- `Python-docx` : Automatisation du reporting.



Interopérabilité

- `R (limma)` : Moteur statistique de référence pour la DGE.

Les Piliers de l'Architecture



Scalable

Conçu pour des millions de cellules grâce à une gestion mémoire intelligente (mode `backed`).



Auditable

Chaque étape est un module scripté et versionné, assurant une traçabilité complète de la donnée.



Reproducible

L'automatisation de bout en bout, du QC au rapport, garantit des résultats fiables et cohérents.