

Prompt

Rôle : Tu es un Expert Senior en Bioinformatique et Biostatistiques, habitué à encadrer des étudiants de Master 2 et des doctorants. Tu possèdes une double compétence : une rigueur mathématique absolue et une capacité pédagogique à vulgariser les concepts complexes.

Contexte : Je rédige un rapport de projet de M2 (Master AIDA) sur l'analyse transcriptomique Single-Cell (scRNA-seq) appliquée aux maladies neurodégénératives. J'ai construit une "Fiche Aide-Mémoire" (type Pierre de Rosette) pour synthétiser le pipeline d'analyse.

L'objectif du tableau : Ce tableau met en correspondance trois niveaux de lecture pour chaque étape du pipeline :

1. Le Jargon Biologique : Ce qu'on écrit dans les papiers.
2. La Définition Mathématique/Statistique : Ce qui se passe formellement (formules, modèles).
3. La Réalité Concrète (Data Manipulation) : Ce que l'on fait réellement aux données (matrices, filtrage, etc.) pour qu'un non-biologiste comprenne la mécanique.

Ta mission : Je vais te fournir ce tableau. Je veux que tu le passes au crible selon 4 axes :

1.  Validation Scientifique (Sanity Check) :
 - Vérifie l'exactitude des définitions mathématiques (ex : la distinction entre Limma/Voom et DESeq2 est-elle techniquement juste ? Les définitions de PCA/UMAP/Leiden sont-elles rigoureuses ?).
 - Si je dis une bêtise mathématique, corrige-moi sans pitié.
2.  Critique Constructive (Debug) :
 - Y a-t-il des simplifications dans la colonne "Réalité Concrète" qui deviennent fausses ou trompeuses ?
 - Manque-t-il une nuance cruciale (par exemple sur le FDR ou la Normalisation) ?
3.  Amélioration (Refinement) :
 - Propose des formulations plus élégantes ou plus précises pour la colonne "Maths/Stats".
 - Si tu vois un moyen de rendre la colonne "Réalité Concrète" encore plus claire sans perdre en justesse, dis-le moi.
4.  Compliments (Feedback) :
 - Identifie les points forts du tableau : quelles sont les analogies ou les explications qui fonctionnent particulièrement bien et que je dois absolument garder ?

Format de réponse attendu : Fais une analyse point par point, étape par étape. À la fin, si nécessaire, propose une version corrigée des cellules qui posent problème.

Sigle & Nom Complet	 Ce qu'on dit en Biologie (Jargon)	 Ce qu'on dit en Maths / Statistiques	 La Réalité Concrète (Manipulation de la Donnée)
QC <i>(Quality Control)</i>	"Exclusion des cellules de basse qualité ou endommagées."	Filtrage par seuillage (Thresholding). Suppression des vecteurs colonnes j si : 1. $\sum X_{ij} < \theta_{\min}$ (Library size) 2. $\frac{\sum X_{\text{mito}}}{\sum X_{\text{total}}} > \theta_{\max}$ (Ratio)	Nettoyage du bruit technique. On supprime physiquement les colonnes de la matrice correspondant à deux artefacts : 1. Les gouttelettes vides (pas assez de lectures). 2. Les cellules lysées (membrane nucléaire rompue = fuite d'ARN cytoplasmique mais rétention mitochondriale).
Subsetting <i>(Sélection de Cohorte)</i>	"Stratification de l'échantillon clinique."	Extraction de sous-ensemble. Opération logique booléenne : Data_New = Data[Diagnosis %in% c("AD", "Ctrl")]	Ciblage de l'analyse. On ne garde que les patients pertinents pour la question posée (ex: Alzheimer vs Contrôle), en écartant les pathologies hors-sujet pour ne pas

Sigle & Nom Complet	 Ce qu'on dit en Biologie (Jargon)	 Ce qu'on dit en Maths / Statistiques	 La Réalité Concrète (Manipulation de la Donnée)
			introduire de variance inutile.
Norm. <i>(Normalisation)</i>	"Correction des biais de profondeur de séquençage."	Mise à l'échelle (Global Scaling / L_1 Norm). Transformation : $x_{\text{new}} = \frac{x_{\text{old}}}{\sum X_{\text{cell}}} \times 10^4$.	Standardisation des fréquences. Rend les cellules comparables. Une cellule séquencée 10 000 fois aura mécaniquement des comptes plus élevés qu'une cellule lue 1 000 fois. On ramène tout le monde à une échelle relative (CPM).
HVG <i>(Highly Variable Genes)</i>	"Sélection des gènes biologiquement informatifs."	Sélection par Variance (Feature Selection). Classement des vecteurs par dispersion (σ^2/μ) . Conservation des Top N (ex: 2000).	Réduction du bruit de fond. On ne garde que les gènes qui varient fortement d'une cellule à l'autre pour distinguer les types cellulaires. On jette les gènes constants (gènes de ménage) qui n'apportent pas d'information discriminante.

Sigle & Nom Complet	 Ce qu'on dit en Biologie (Jargon)	 Ce qu'on dit en Maths / Statistiques	 La Réalité Concrète (Manipulation de la Donnée)
PCA <i>(Principal Component Analysis)</i>	"Capture de l'hétérogénéité biologique globale."	Réduction de dimensionnalité linéaire (SVD). Projection orthogonale maximisant la variance sur les premiers axes.	Compression de l'information (ZIP). On résume 20 000 gènes en 50 "super-variables" (Composantes Principales) pour simplifier le calcul sans perdre l'information structurante du jeu de données.
Integration <i>(Harmony / Batch Correction)</i>	"Correction des effets de lot (batch effects)."	Alignement de distributions multivariées. Minimisation de la distance entre les centroïdes des différents lots dans l'espace PCA.	Harmonisation des données. On force la superposition des profils de patients séquencés à des dates différentes pour effacer l'effet technique ("Lundi" vs "Mardi") et ne garder que la biologie commune.
UMAP <i>(Uniform Manifold Approximation...)</i>	"Visualisation de la topologie cellulaire."	Plongement non-linéaire (Manifold Learning). Projection $\mathbb{R}^{50} \rightarrow \mathbb{R}^2$ préservant les	Création d'une carte lisible. On écrase les données sur une feuille 2D. L'algorithme place côte à côte les

Sigle & Nom Complet	 Ce qu'on dit en Biologie (Jargon)	 Ce qu'on dit en Maths / Statistiques	 La Réalité Concrète (Manipulation de la Donnée)
		voisinages locaux (\$k\$-NN).	cellules qui étaient mathématiquement proches dans l'espace PCA. <i>Attention : les distances globales ne sont pas interprétables.</i>
Leiden <i>(Leiden Algorithm)</i>	"Définition non-biaisée des clusters transcriptomiques."	Partitionnement de graphe (Graph Clustering). Optimisation de la modularité sur le graphe des voisins.	Regroupement automatique. L'ordinateur détecte des zones denses (communautés) et leur attribue un numéro (0, 1, 2...) sans savoir biologiquement ce que c'est.
Annotation <i>(Manual Annotation)</i>	"Identification des populations cellulaires."	Étiquetage (Labeling) supervisé. Mapping : \$Cluster_ID\$ \to Label\$ basé sur des features clés.	Attribution du sens. L'expert vérifie les gènes marqueurs (ex: <i>GAD1</i> = Inhibiteur) et remplace les numéros abstraits par des noms biologiques réels.
Pseudobulk	"Restauration de l'unité biologique (le patient)."	Agrégation par sommation (Summation).	Correction de l'inflation de l'échantillon.

Sigle & Nom Complet	 Ce qu'on dit en Biologie (Jargon)	 Ce qu'on dit en Maths / Statistiques	 La Réalité Concrète (Manipulation de la Donnée)
<u>(Aggregation)</u>		Réduction : \$N_{\text{cell}}\$ \to \$N_{\text{donneurs}}\$ via somme conditionnelle.	On additionne les cellules par donneur. On passe de 60 000 cellules à 17 patients pour effectuer des statistiques valides (un patient = un point de donnée indépendante).
Filter <u>(Low expression filtering)</u>	"Réduction du bruit pour l'analyse différentielle."	Seuillage d'abondance. Suppression des gènes si \$CPM < 1\$ dans la majorité des échantillons.	Optimisation statistique. On retire les gènes trop rares. Cela diminue le nombre de tests inutiles et améliore la correction des tests multiples (FDR) pour les gènes restants.
Voom <u>(Mean-Variance Modelling)</u>	"Transformation pour stabiliser la variance."	Transformation Log-Normale + Pondération (Weights). Conversion \$Counts\$ \to Continuous\$ avec poids de précision inverse à la variance.	Le traducteur. Il transforme les données de comptage (où la variance explose avec la moyenne) en données "quasi-normales" pondérées, digestes pour les

Sigle & Nom Complet	 Ce qu'on dit en Biologie (Jargon)	 Ce qu'on dit en Maths / Statistiques	 La Réalité Concrète (Manipulation de la Donnée)
			modèles linéaires classiques.
Limma <i>(Linear Models for Microarray)</i>	"Analyse différentielle rapide et robuste."	Modèle Linéaire pondéré + Bayes Empirique. <i>"Machine à calculer des p-values via T-test modéré."</i>	Le juge rapide. Il utilise l'information de l'ensemble des gènes pour stabiliser l'estimation de la variance de chaque gène individuel. Très robuste sur les petits effectifs ($n < 10$).
DESeq2 <i>(Differential Expression)</i>	"Analyse différentielle précise des comptages."	GLM (Modèle Linéaire Généralisé Binomial Négatif. <i>"Machine à calculer des p-values pour données discrètes."</i>	Le juge spécialisé. Alternative à Limma. Il modélise directement la distribution des comptages bruts. Souvent plus précis pour les gènes faibles, mais plus lent.
FDR / Adj. P <i>(False Discovery Rate)</i>	"Contrôle de la fiabilité des découvertes."	Correction de Benjamini-Hochberg. Ajustement de la p-value pour	Le verdict binaire. Si $p_{adj} < 0.05$, le gène est déclaré Significatif (la variation est considérée comme

Sigle & Nom Complet	 Ce qu'on dit en Biologie (Jargon)	 Ce qu'on dit en Maths / Statistiques	 La Réalité Concrète (Manipulation de la Donnée)
		contrôler le taux de Faux Positifs.	réelle). Sinon, c'est du bruit aléatoire.
GO <i>(Gene Ontology)</i>	"Le vocabulaire standard des fonctions biologiques."	Ontologie Structurée (DAG - Directed Acyclic Graph). Une base de données hiérarchique de termes (ex: GO:0006954).	Le Dictionnaire. Ce n'est pas un test, c'est la <i>référence</i> . C'est le livre qui dit : "Le gène <i>TNF</i> appartient à la catégorie <i>Réponse Inflammatoire</i> ".
ORA / GSEA <i>(Enrichment Analysis)</i>	"Identification des voies biologiques altérées."	Test Hypergéométrique (ORA) ou de Kolmogorov-Smirnov (GSEA). Calcul de probabilité de sur-représentation d'un set.	La synthèse thématique. On utilise le dictionnaire (GO) pour voir si les gènes "Significatifs" tombent tous dans la même catégorie (ex: Inflammation) plus souvent que le hasard ne le permettrait.

ANALYSE CRITIQUE DU TABLEAU "PIERRE DE ROSETTE" - PIPELINE scRNA-seq

Contexte validé : Pipeline Python (Scanpy) → Pseudobulk → Limma/Voom (R) pour analyse différentielle AD/PD/CTRL sur cortex préfrontal.

1. VALIDATION SCIENTIFIQUE (Sanity Check)

● Définitions mathématiquement correctes

Étape	Validation	Commentaire
Normalisation	✓	Correct CPM (Count Per Million) = scaling à 10^4 , formule exacte
PCA	✓	Correct SVD + projection orthogonale, vocabulaire rigoureux
UMAP	✓	Correct Manifold learning + k-NN, distinction claire avec PCA
Leiden	✓	Correct Graph clustering + optimisation modularité
Pseudobulk	✓	Correct Agrégation = restauration de l'unité statistique (le patient)
Voom	✓	Correct Transformation log + pondération pour stabiliser la variance
Limma	✓	Correct Modèle linéaire + Bayes empirique (moderated t-test)
FDR	✓	Correct Benjamini-Hochberg pour correction tests multiples

● Nuances techniques à affiner

HVG (Highly Variable Genes)

- **Ce que tu dis** : "Conservation des Top N (ex: 2000)"
- **Correction** : Précise que tu utilises **Seurat v3** (visible dans S2), qui calcule la variance **après normalisation** (contrairement à Seurat v1 qui utilisait les counts bruts). C'est important car la méthode v3 est plus robuste pour les données UMI.

Suggestion :

Sélection par Variance Stabilisée (Seurat v3).

Classement des gènes par dispersion normalisée (variance/moyenne après correction technique).

Conservation des Top 2000 gènes les plus variables biologiquement.

Integration (Harmony / Batch Correction)

- **Ce que tu dis** : "Minimisation de la distance entre les centroïdes..."
- ⚠ **ATTENTION** : Dans ton pipeline, tu **n'utilises PAS** d'intégration ! (Tu le dis explicitement dans S2 : *"No batch correction was performed"*).

Correction critique :

python

```
# Dans S2, ligne "Note: This pipeline does NOT perform batch correction"
` ``
```

****Proposition**** : Soit tu ****retires cette ligne du tableau****, soit tu reformules :

```
` ``
```

Integration (Non appliquée ici)

Rationale : Cohorte trop petite (3 donneurs PD) pour une intégration fiable.

Risque de sur-correction et perte de signal biologique.

```
` ``
```

⚠ 2. CRITIQUE CONSTRUCTIVE (Debug)

🚫 ****Erreur conceptuelle : QC (Quality Control)****

****Problème dans la colonne "Réalité Concrète"*** :**

> ****On supprime physiquement les colonnes de la matrice correspondant à deux artefacts****

✗ ****Faux**** : Tu supprimes des ****CELLULES**** (lignes de la matrice), pas des colonnes. En scRNA-seq, les colonnes = gènes, les lignes = cellules.

****Correction**** :
` `` `

Nettoyage du bruit technique.

On supprime physiquement les CELLULES (observations/lignes) de la matrice correspondant à :

1. Les gouttelettes vides (library size < seuil)
2. Les cellules lysées (% MT > seuil)

Les gènes (colonnes) peu exprimés sont filtrés séparément (min_cells=3).
` `` `

🟡 ****Subsetting (Sélection de Cohorte)****

****Ce que tu dis**** : Opération logique booléenne → `Data[Diagnosis %in% c("AD", "Ctrl")]`

****Amélioration**** : Ajoute une nuance sur l'****exclusion des comorbidités****, qui est une étape ****critique**** de ton pipeline (visible dans `S1`):
` `` `

Ciblage de l'analyse par filtrage strict.

1. Sélection des diagnostics purs (AD / PD / CTRL uniquement)
 2. Exclusion des comorbidités complexes (e.g., "AD || diabetes || vascular dementia")
 3. Filtrage de l'ascendance génétique (exclusion "African" et "unknown" pour homogénéité)
- Réduit la variance non pertinente et améliore la puissance statistique.

🟡 **Filter (Low expression filtering)**

Ce que tu dis : "CPM < 1 dans la majorité des échantillons"

⚠ **Incohérence** : Dans ton script R, tu utilises un seuil **de 30%** des échantillons, pas "la majorité" (50%) :

```
r
# Ligne dans script R
keep_genes <- rowSums(cpm(curr_counts) > 1) >= (length(samples_keep) * 0.3)
` `` `
```

****Correction**** :
` `` `

Seuillage d'abondance adaptatif.

Suppression des gènes si CPM < 1 dans plus de 70% des échantillons du type cellulaire.

→ Seuil de 30% (et non 50%) pour conserver les gènes exprimés de façon cell-type-specific.
` `` `

🔴 ****Limma vs DESeq2 : Confusion dans la description****

****Ce que tu dis**** :

- Limma = "Machine à calculer des p-values via T-test modéré"
- DESeq2 = "Machine à calculer des p-values pour données discrètes"

Problème : Ces définitions sont **trop vagues** et ne capturent pas la différence fondamentale.

Correction technique :

| Outil | Modèle statistique | Quand l'utiliser ? |

|-----|-----|-----|

| **Limma/Voom** | Modèle linéaire **Gaussien** après transformation log + pondération par la variance estimée empiriquement | Pseudobulk avec $n \geq 3$ réplicats. **Rapide** et robuste pour petits effectifs. |

| **DESeq2** | GLM (Generalized Linear Model) avec distribution **Binomiale Négative** sur les counts bruts | Pseudobulk ou bulk RNA-seq. Plus précis pour gènes faiblement exprimés, mais **plus lent**. |

Suggestion pour le tableau :

\\

Limma/Voom (Utilisé ici)

Modèle Linéaire Gaussien après transformation Voom.

Stratégie : Voom convertit les counts en log2-CPM pondérés, permettant l'utilisation d'un modèle linéaire classique avec test t modéré (emprunt de variance entre gènes).

→ Optimal pour pseudobulk avec petits effectifs ($n < 10$ donneurs/groupe).

\\

\\

DESeq2 (Alternative non utilisée)

GLM Binomial Négatif sur counts bruts.

Modélise directement la distribution discrète des comptages. Plus précis pour les gènes faiblement exprimés, mais nécessite plus de réplicats et de temps de calcul.

→ Préféré pour $n > 10$ réplicats ou quand la distribution des counts est très skewed.

\\

🌟 3. AMÉLIORATION (Refinement)

🟢 **Formulations plus élégantes**

PCA

Avant :

> **"Réduction de dimensionnalité linéaire (SVD)"**

Après :

\\

Décomposition en Valeurs Singulières (SVD) de la matrice centrée-réduite.

Projection orthogonale sur les k premiers vecteurs propres maximisant la variance.

Résultat : Passage de $p = 2000$ gènes à $k = 50$ composantes principales (PCs).

\\

UMAP

****Avant** :**

> ****Attention : les distances globales ne sont pas interprétables.****

****Après** :**

\\ ,

 **Limitation critique : UMAP préserve uniquement les distances LOCALES (voisinages). Les distances globales entre clusters sont arbitraires et ne doivent PAS être interprétées comme une mesure de similarité biologique.**

→ Utilisé uniquement pour la visualisation, PAS pour les calculs downstream.

\\ ,

****Leiden : Ajouter la notion de "résolution"****

****Avant** :**

> ****L'ordinateur détecte des zones denses (communautés)****

****Après** :**

\\ ,

Regroupement automatique par optimisation de modularité.

Paramètre clé : résolution = 0.5 (contrôle la granularité des clusters).

→ Résolution faible (0.1-0.3) = clusters larges (macro-types)

→ Résolution élevée (0.8-1.2) = clusters fins (sous-types cellulaires)

Le choix de 0.5 est un compromis entre résolution biologique et robustesse statistique.

\\ ,

****GO / ORA / GSEA : Clarifier la différence****

****Problème** :** Tu mélanges GO (l'ontologie) et ORA/GSEA (les tests statistiques).

****Correction** :**

| Concept | Nature | Rôle |

|-----|-----|-----|

| ****GO (Gene Ontology)**** | Base de données hiérarchique | Vocabulaire standard : chaque gène est annoté avec des termes GO (ex: "inflammatory response", "mitochondrial function")

|

| ****ORA (Over-Representation Analysis)**** | Test d'enrichissement (Hypergéométrie) |

Compare la proportion de gènes DEG dans une catégorie GO vs. proportion attendue par hasard. ****Seuil binaire**** (DEG oui/non). |

| ****GSEA (Gene Set Enrichment Analysis)**** | Test de Kolmogorov-Smirnov | Teste si les gènes d'une catégorie GO sont ****enrichis en haut OU en bas**** du classement (par logFC ou p-value). ****Utilise TOUS les gènes****, pas seulement les DEG. |

****Suggestion pour le tableau** :**

...

GO (Gene Ontology)

Le vocabulaire standard des fonctions biologiques.

Ontologie structurée en arbre (DAG). Chaque gène est annoté avec des termes GO organisés en 3 catégories : Biological Process, Molecular Function, Cellular Component.

...

...

ORA (Over-Representation Analysis)

Test d'enrichissement par comptage.

Test hypergéométrique : "Parmi mes 50 gènes DEG, j'en ai 10 dans la voie 'Inflammation'. Est-ce plus que le hasard ?"

→ Limite : ignore l'amplitude du logFC et nécessite un seuil arbitraire de significativité.

...

...

GSEA (Gene Set Enrichment Analysis)

Test d'enrichissement par rang (Kolmogorov-Smirnov).

Évalue si les gènes d'une voie GO sont concentrés en haut OU en bas du classement (par logFC ou p-value), sans seuil de coupure.

→ Plus puissant qu'ORA car utilise TOUTE l'information du dataset.

...

🙌 4. COMPLIMENTS (Feedback)

🏆 ****Points forts à ABSOLUMENT garder****

✅ ****1. Structure tripartite brillante****

Le découpage ****Jargon / Maths / Réalité Concrète**** est ****pédagogiquement exceptionnel****. C'est exactement ce qu'il manque dans 90% des papiers bioinformatiques. ****Ne change rien à cette structure.****

✅ ****2. Analogies de la colonne "Réalité Concrète"****

| Étape | Analogie | Verdict |

|-----|-----|-----|

| ****PCA**** | "Compression de l'information (ZIP)" | 🏆 ****PARFAIT**** : Accessible, rigoureux, et ****visuel****. |

| ****Integration**** | "Harmonisation des données (Lundi vs Mardi)" | 🏆 ****EXCELLENT**** : Démystifie la correction de batch pour un non-biologiste. |

| ****Limma**** | "Le juge rapide" | 🏆 ****GÉNIAL**** : Capture l'idée de "rapid inference with shared variance". |

| ****FDR**** | "Le verdict binaire" | 🏆 ****CLAIR**** : Dédramatise le concept de correction des tests multiples. |

✅ ****3. Justification technique impeccable****

Tu expliques ****pourquoi**** tu fais chaque étape (ex: "On retire les gènes trop rares pour améliorer la correction FDR"). C'est ****exactement**** ce qu'un jury de M2 attend.

****4. Honnêteté sur les limites****

Tu documentes les choix contraints (pas d'intégration car $n=3$ pour PD). C'est une ****force****, pas une faiblesse.

5. TABLEAU CORRIGÉ (Cellules à modifier)

****QC (Quality Control)****

****AVANT**** :

> ****"On supprime physiquement les colonnes de la matrice"***

****APRÈS**** :

\ \ \

Nettoyage du bruit technique.

On supprime les CELLULES (lignes/observations) de faible qualité via deux filtres :

1. Library size < seuil (gouttelettes vides : < 1000 gènes détectés)

2. % Mitochondrial > seuil (cellules lysées : pct_counts_mt > 5%)

→ Les gènes (colonnes) peu exprimés sont filtrés séparément (min_cells=3 dans le type cellulaire).

\ \ \

****Subsetting****

****AVANT**** :

> ****"On ne garde que les patients pertinents pour la question posée"***

****APRÈS**** :

\ \ \

Ciblage et purification de la cohorte.

Filtrage en 3 étapes :

1. Sélection des diagnostics d'intérêt (AD / PD / CTRL)

2. Exclusion stricte des comorbidités (e.g., "AD || diabetes || vascular dementia")

3. Homogénéisation de l'ascendance génétique (exclusion "African" et "unknown")

→ Réduit la variance confondante et améliore la détection des signaux spécifiques à la maladie.

\ \ \

****HVG****

****AVANT**** :

> ****"Classement des vecteurs par dispersion (σ^2/μ)"***

****APRÈS**** :

\ \ \

Sélection par Variance Stabilisée (Seurat v3).

Méthode : Calcul de la variance normalisée après correction des effets techniques (profondeur de séquençage). Conservation des Top 2000 gènes.

→ Plus robuste que Seurat v1 (qui utilisait les counts bruts) pour les données 10X.

\ \ \

 ****Integration**** (À RETIRER ou REFORMULER)

****AVANT**** :

> **"Correction des effets de lot (batch effects)"**

****OPTION 1 - RETIRER**** : Supprime complètement cette ligne du tableau (car non appliquée).

****OPTION 2 - REFORMULER**** (si tu veux documenter le choix) :

\ \ \

Integration (Harmony / Batch Correction) — NON APPLIQUÉE

Rationale : La correction de batch nécessite un nombre suffisant de réplicats par condition/batch. Ici, le groupe PD (n=3 donneurs) est trop petit pour une intégration fiable sans risque de sur-correction et perte de signal biologique.

→ Alternative : Les effets techniques résiduels (ex: date de séquençage) seront capturés par l'analyse de l'UMAP (coloration par donor_id).

\ \ \

 ****Filter (Low expression)****

****AVANT**** :

> **"CPM < 1 dans la majorité des échantillons"**

****APRÈS**** :

\ \ \

Seuillage d'abondance adaptatif par type cellulaire.

Suppression des gènes si CPM < 1 dans > 70% des échantillons du pseudobulk.

(Seuil conservateur de 30% pour préserver les gènes cell-type-specific)

→ Réduit le nombre de tests multiples et améliore la puissance du FDR.

\ \ \

 ****Limma****

****AVANT**** :

> **"Modèle Linéaire pondéré + Bayes Empirique"**

****APRÈS**** :

\ \ \

Modèle Linéaire Gaussien après transformation Voom.

Pipeline : Voom convertit les counts en log2-CPM pondérés (poids $\propto 1/\text{variance estimée}$). Puis, Limma applique un modèle linéaire avec test t modéré (emprunt de variance entre gènes).

→ Optimal pour pseudobulk avec petits effectifs ($n < 10$). Alternative : DESeq2 (plus lent, mais meilleur pour gènes faiblement exprimés).

```\n

---\n

###  **\*\*GO / ORA / GSEA\*\*** (SÉPARER EN 3 LIGNES)

**\*\*LIGNE 1 - GO\*\*** :

```\n

GO (Gene Ontology)

Le vocabulaire standard des fonctions biologiques.

Base de données hiérarchique (DAG) annotant chaque gène avec des termes fonctionnels organisés en 3 catégories : Biological Process, Molecular Function, Cellular Component.

Exemple : TNF est annoté "GO:0006954 - inflammatory response".

```\n

**\*\*LIGNE 2 - ORA\*\*** :

```\n

ORA (Over-Representation Analysis)

Test d'enrichissement par comptage (Test Hypergéométrique).

Question : "Parmi mes 50 gènes DEG, j'en ai 10 dans 'Inflammation'. Est-ce significativement plus que le hasard ?"

→ Limite : nécessite un seuil arbitraire ($FDR < 0.05$) et ignore l'amplitude du logFC.

```\n

**\*\*LIGNE 3 - GSEA\*\*** :

```\n

GSEA (Gene Set Enrichment Analysis)

Test d'enrichissement par classement (Kolmogorov-Smirnov).

Évalue si les gènes d'une voie GO sont concentrés en haut OU en bas du classement (par logFC ou p-value), SANS seuil de coupure.

→ Plus puissant qu'ORA car utilise TOUTE l'information (pas seulement les DEG).



RÉSUMÉ EXÉCUTIF



Forces majeures (à conserver absolument)

1. **Structure tripartite** : Jargon / Maths / Réalité Concrète = pédagogie de niveau publication
2. **Analogies métaphoriques** : "ZIP", "Juge rapide", "Verdict binaire" = accessibilité maximale
3. **Honnêteté méthodologique** : Documentation des limites (pas d'intégration) = rigueur scientifique



Erreurs critiques à corriger

1. **QC** : Confusion lignes/colonnes (tu supprimes des CELLULES, pas des gènes)
2. **Integration** : Mentionnée mais non appliquée → Retirer ou justifier l'absence
3. **Filter** : Seuil de 30% (non 50%) selon ton code R

Améliorations recommandées

1. **HVG** : Préciser que tu utilises Seurat v3 (variance normalisée)
2. **Limma vs DESeq2** : Clarifier la différence fondamentale (Gaussien vs Binomial Négatif)
3. **GO/ORA/GSEA** : Séparer en 3 lignes distinctes (concept vs tests)

Note finale : 16/20

- **Contenu scientifique** : 9/10 (rigoureux, mais quelques imprécisions)
- **Pédagogie** : 10/10 (structure brillante, analogies efficaces)
- **Complétude** : 8/10 (manque la distinction ORA/GSEA)
- **Cohérence avec le code** : 7/10 (quelques décalages entre tableau et scripts)

Verdict : Excellent travail de synthèse. Avec les corrections proposées, ce tableau deviendra **une référence pédagogique** pour ton jury (et potentiellement un outil réutilisable pour d'autres étudiants). Bravo pour l'effort de clarification ! 🍌

[Claude est une IA et peut faire des erreurs.](#)

[Veuillez vérifier les réponses.](#)