



Figure 1 : Pipeline d'analyse bioinformatique des données single-cell.

Légende : Le flux de travail part des données brutes de séquençage de noyaux uniques (snRNA-seq) et inclut les étapes de contrôle qualité, de normalisation, de clustering non supervisé et d'annotation manuels types cellulaires. Les données sont ensuite agrégées au format pseudobulk par type cellulaire et par donneur afin de préparer les matrices de comptage et d'annotation de comptage et de métadonnées pour l'analyse d'expression différentielle sous R.

Le Point de Départ : Un Atlas Brut Vaste et Complexe

Le jeu de données initial est un atlas public de snRNA-seq du cortex humain, caractérisé par sa grande échelle et son hétérogénéité pathologique.

Taille du dataset brut :

693 682 cellules (noyaux)


34 176 gènes

Complexité clinique :


Le dataset inclut de multiples diagnostics et de nombreuses comorbidités, rendant une analyse directe impossible.

La première étape cruciale est de définir une cohorte d'étude ciblée et statistiquement cohérente.

Visuel : Distribution des Cellules par Pathologie (Top 15)



Étape 1a : Définition de la Cohorte d'Étude



Pour garantir la validité de la comparaison, nous appliquons des filtres stricts pour isoler des groupes diagnostiques purs et assurer la cohérence génétique de la cohorte.

Filtre sur le diagnostic :

- Conservation exclusive des donneurs avec les diagnostics :
 - "normal" (CTRL)
 - "dementia || *Alzheimer disease*" (AD)
 - "dementia || *Parkinson disease*" (PD)
- **Critère** : Toutes les formes de comorbidités sont systématiquement exclues de l'analyse.

Filtre sur l'ascendance génétique :


- **Objectif** : Limiter la variabilité génétique de fond au sein des groupes.
- **Règle** : Les cellules de donneurs à l'ascendance "African" ou "unknown" sont retirées des groupes AD et CTRL. Le groupe PD est filtré pour exclure l'ascendance "African".

Étape 1b : Contrôle Qualité (QC) au Niveau Cellulaire


Après la sélection de la cohorte, un contrôle qualité technique est appliqué pour éliminer les artéfacts de séquençage et ne conserver que les noyaux de haute qualité.

Seuils numériques de QC :

- Nombre de gènes détectés par cellule :
 - $> 1\,000$ gènes : Pour exclure les débris cellulaires.
 - $< 6\,000$ gènes : Pour éliminer les doublets potentiels (deux noyaux capturés ensemble).
- Pourcentage de gènes mitochondriaux :
 - $< 5\%$: Pour exclure les cellules stressées ou en apoptose, qui présentent une expression mitochondriale anormalement élevée.




Visuel : Distributions des métriques de QC



Résultat de l'Étape 1 : Une Cohorte d'Analyse Finale

L'application combinée des filtres cliniques et techniques réduit drastiquement le dataset pour former une cohorte d'étude propre et focalisée.




Étape 2a : Normalisation et Sélection des Gènes Variables

Le traitement standard single-cell vise à corriger les biais techniques et à focaliser l'analyse sur les gènes porteurs du signal biologique le plus pertinent.

1. Normalisation

Les comptages de chaque cellule sont normalisés à un total de 10 000 UMI (`target_sum=1e4`).


Objectif : Corriger les variations de profondeur de séquençage entre les cellules.



2. Transformation Logarithmique

Une transformation `log1p` est appliquée.

Objectif : Stabiliser la variance et réduire l'influence disproportionnée des gènes très fortement exprimés.



3. Sélection des Gènes Hautement Variables (HVG)

2 000 gènes les plus variables sont sélectionnés (méthode `seurat_v3`).

Objectif : Réduire la dimensionnalité et le bruit en ne conservant que les gènes qui différencient les populations cellulaires.



4. Mise à l'échelle (Scaling)

Les données sont centrées-réduites (Z-score), avec une valeur maximale écrêtée à 10.

Objectif : Assurer que tous les gènes ont un poids équivalent dans l'analyse en composantes principales (ACP).



Étape 2b : Réduction de Dimensionnalité et Clustering

À partir des gènes variables, nous réduisons la dimensionnalité des données pour identifier des groupes de cellules biologiquement cohérents (clusters).

Analyse en Composantes Principales (ACP) :

Les **30 premiers composants principaux (PCs)** sont retenus, capturant la majorité de la variance biologique du dataset.


Construction du Graphe de Voisinage (kNN) :

Un graphe est construit en connectant chaque cellule à ses **k=15 plus proches voisins** dans l'espace des 30 PCs.

Clustering :

L'algorithme de **Leiden** est appliqué sur le graphe kNN avec une **résolution de 0.5** pour partitionner les cellules en clusters.

Visuel : Projection UMAP des clusters de Leiden




Étape 3a : Annotation Manuelle des Types Cellulaires

Les clusters non supervisés reçoivent une identité biologique grâce à une annotation manuelle basée sur l'expression de gènes marqueurs connus.

Méthode :

- L'annotation a été réalisée manuellement par des experts.
- Chaque cluster de Leiden a été associé à un type cellulaire en se basant sur l'expression de marqueurs canoniques validés par la littérature scientifique.



Résultat : 8 macro-types cellulaires définis

1. Neurones excitateurs
2. Neurones inhibiteurs
3. Astrocyte Homéostatique
4. Astrocyte Réactif
5. Microglie
6. Oligodendrocyte/OPC
7. Support/Vasculaire/Immun
8. Qualité faible/Inconnu (à exclure)

Étape 3b : Vérification de la Robustesse pour l'Analyse Pseudobulk

Pour garantir la fiabilité de l'analyse d'expression différentielle, nous vérifions que chaque type cellulaire annoté est suffisamment représenté à travers la cohorte de donneurs.

Critère de robustesse appliqué :


- Chaque macro-type cellulaire doit être représenté par au moins **5 donneurs distincts**.
- Chacun de ces donneurs doit contribuer avec un minimum de **20 cellules** à ce macro-type.

Objectif :

- Éviter que les résultats d'un type cellulaire soient biaisés par un ou deux donneurs seulement.
- Assurer une puissance statistique adéquate pour la comparaison entre les groupes pathologiques (AD, PD, CTRL).


Validation :

- Tous les macro-types principaux, y compris les sous-types d'astrocytes, ont passé ce critère avec succès. La microglie activée (Cluster 18) a échoué ce test et a été regroupée avec la microglie homéostatique.



Étape 4a : Agrégation des Cellules en Échantillons Pseudobulk

Pour réaliser une analyse d'expression différentielle robuste, les cellules individuelles sont agrégées pour former des échantillons "pseudobulk", où chaque échantillon représente un type cellulaire pour un donneur donné.



Échantillon = Macro-type cellulaire annoté + ID du donneur

Avantage :

Cette approche traite chaque donneur comme une réplication biologique indépendante, ce qui est une condition nécessaire pour les modèles statistiques comme DESeq2. Elle augmente la robustesse en moyennant le bruit technique au niveau single-cell.

Étape 4b : Filtrages Statistiques sur les Échantillons Agrégés


Deux filtres finaux sont appliqués sur les échantillons pseudobulk pour garantir la qualité et la pertinence des données entrant dans le modèle statistique.

1. Filtre sur la taille de l'échantillon :

- Les échantillons pseudobulk constitués de **moins de 20 cellules** sont retirés de l'analyse.
- **Raison** : Un nombre de cellules trop faible ne permet pas une estimation fiable du profil d'expression.

2. Exclusion manuelle des populations de faible qualité :


- Tous les échantillons correspondant au macro-type 'Unknown/Low Quality' sont exclus.
- **Raison** : Ces populations représentent des artefacts techniques et ne doivent pas être incluses dans l'analyse différentielle biologique.



Résultat : 7 types cellulaires robustes sont conservés pour l'analyse finale.

Sortie Finale : Données Prêtes pour l'Analyse sous R avec DESeq2

Le pipeline génère deux fichiers CSV essentiels, formatés pour l'analyse d'expression différentielle (DGE) dans l'environnement R.



1. Matrice de comptages bruts (pseudobulk_counts.csv)

- **Format** : Gènes en lignes, échantillons pseudobulk en colonnes.
- **Contenu** : Nombres entiers de comptages bruts sommés.
- **Dimensions finales** : 2 000 gènes × 96 échantillons.



ID Donneur	Diagnostic	Sexe	Type Cellulaire
Donneur	Diagnostic	M	Type Cellulaire
Donneur	Diagnostic	M	Type Cellulaire
Donneur	DCC	M	Type Cellulaire
Donneur	DCC	F	Type Cellulaire
...	...	...	...

2. Table de métadonnées (pseudobulk_metadata.csv)

- **Format** : Échantillons en lignes, variables en colonnes.
- **Contenu** : Décrit chaque échantillon (ID donneur, diagnostic, sexe, type cellulaire, etc.). Indispensable pour la construction du modèle statistique.

Résumé du Pipeline Analytique

DONNÉES BRUTES

Entrée : 693 682 cellules x 34 176 gènes



QC & SÉLECTION DE COHORTE

Filtres : Diagnostic (AD, PD, CTRL), Ascendance

QC : >1k & <6k gènes, <5% MT

Sortie : 62 800 cellules de 17 donneurs



TRAITEMENT SINGLE-CELL

Étapes : Normalisation, Log1p, Scaling

Paramètres : 2000 HVG, 30 PCs, k=15, Leiden (res=0.5)

Sortie : 23 clusters non supervisés



ANNOTATION

Méthode : Manuelle via gènes marqueurs

Critère : Robustesse (≥ 5 donneurs, ≥ 20 cellules / type)

Sortie : 8 macro-types cellulaires annotés



ANALYSE PSEUDOBULK

Agrégation : Par (Type Cellulaire x Donneur)

Filtres : ≥ 20 cellules / échantillon, Exclusion de 'Low Quality'

Sortie : 96 échantillons finaux (7 types cellulaires)



EXPORT POUR R (DESEQ2)

Fichiers : Matrice de comptages (gènes x 96) & table de métadonnées.