

Pipeline analytique snRNA-seq : De la donnée brute à l'analyse différentielle



ÉTAPE 1 : Réduction du dataset (QC + Sélection cohorte)

693 682 cellules → 62 800 noyaux (AD/PD/CTRL)



ÉTAPE 2 : Pipeline single-cell (Normalisation + Clustering)

62 800 noyaux → 2 000 gènes hautement variables → 23 clusters Leiden



ÉTAPE 3 : Annotation des types cellulaires

23 clusters Leiden → 8 macro-types → 7 types retenus pour la DGE



ÉTAPE 4 : Agrégation pseudobulk (Export vers R)

96 échantillons pseudobulk (Type cellulaire × Donneur)

Pipeline implémenté en Python (Scanpy 1.9+) et R (méthodes DGE prévues : limma/voom, DESeq2).

Méthodes et paramètres clés du pipeline

ÉTAPE 1 — Réduction du dataset (1-reduction_of_dataset.ipynb)



Filtrage QC cellulaire :

- n_genes : [1 000 - 6 000]
- pct_counts_mt < 5%



Sélection de cohorte :

- AD : 25 301 cellules (8 donneurs)
- PD : 7 023 cellules (3 donneurs)
- CTRL : 30 476 cellules (6 donneurs)
- **Output final** : 62 800 noyaux × 34 176 gènes


ÉTAPE 2 — Pipeline single-cell (2-single_cell_pipeline.ipynb)



- **Normalisation** : 10 000 UMI/cellule + transformation log1p



- **Sélection HVG** : 2 000 gènes (méthode Seurat v3)




Réduction dimensionnelle :

- PCA : 50 composantes calculées (30 PC utilisées pour le graph de voisinage)
- UMAP : Visualisation 2D



- **Clustering Leiden** : Résolution 0.5 → 23 clusters




- **Identification des gènes marqueurs** : Test de Wilcoxon

ÉTAPE 3 — Annotation cellulaire (3-add_cell_type_annotation.ipynb)



- **Mapping manuel** : 23 clusters Leiden → 8 macro-types cellulaires



- **Types annotés** : Excitatory neuron, Inhibitory neuron, Oligodendrocyte/OPC, Astrocyte Homeostatic, Astrocyte Reactive, Microglia, Support/Vascular/Immune, Unknown/Low Quality



- **Validation** : Décision de regrouper les sous-types de microglie basée sur les seuils pseudobulk (≥20 cellules/échantillon et ≥5 donneurs/type) pour assurer la robustesse statistique.



- **Output** : 7 types cellulaires retenus pour la DGE (après exclusion de "Unknown/Low Quality").

ÉTAPE 4 — Agrégation pseudobulk (4-translation_to_R.ipynb)




- **Agrégation** : Somme des comptages bruts par (Type cellulaire × Donneur)



Filtres statistiques appliqués :

- MIN_CELLS_PER_SAMPLE ≥ 20 cellules
- MIN_DONORS_PER_CLUSTER ≥ 5 donneurs
- Exclusion manuelle : "Unknown/Low Quality"



Output final :

- 96 échantillons pseudobulk (7 types cellulaires)
- Export R : pseudobulk_counts.csv + pseudobulk_metadata.csv